

Aplicação de Técnicas de Segmentação de Imagens com Inteligência Artificial no Apoio à Análise de Montagens Visuais Infantis

Camila Vitória Rodrigues Leite de Sousa¹, Fernando Morales Peres², Guilherme Almeida Roath Machado³, Gustavo Scalabrini Sampaio⁴

^{1,2,3,4}Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

Disciplina: Inteligência Artificial - 7ºJ SI - Noite
Professor: Prof. Dr. Leandro Zerbinatti

gustavo.sampaio@mackenzie.br
{10418554, 10417590, 10376788}@mackenzista.com.br

Resumo. Este projeto apresenta uma aplicação de Inteligência Artificial voltada à segmentação de imagens de montagens visuais realizadas por crianças. A proposta está inserida no contexto de visão computacional e aprendizado profundo, utilizando imagens de uma figura composta por peças recortadas para treinar um modelo capaz de identificar e delimitar individualmente cada componente da montagem. A motivação do trabalho está na possibilidade de tornar a análise visual mais objetiva, organizada e padronizada, oferecendo suporte técnico para a identificação de padrões estruturais nas imagens. Para isso, foi utilizado um dataset composto por imagens digitais fornecidas pelo Centro de Ciências Biológicas e da Saúde da Universidade Presbiteriana Mackenzie, com anotações manuais de segmentação realizadas na plataforma Roboflow. O modelo adotado foi o YOLOv11, da Ultralytics, escolhido por sua capacidade de realizar segmentação de instâncias com bom desempenho. Os resultados obtidos demonstraram desempenho sólido na segmentação das peças, com mAP@0.5 de 0,995 e F1-Score de 0,99, indicando que o modelo foi capaz de reconhecer e delimitar corretamente as regiões de interesse nas imagens analisadas. Dessa forma, o projeto demonstra a aplicação prática de técnicas de Inteligência Artificial em um problema real de análise visual, sem substituir a avaliação humana, mas atuando como ferramenta complementar de apoio à interpretação das imagens.

Palavras-chave: inteligência artificial; visão computacional; segmentação de imagens; aprendizado profundo; YOLOv11; análise de padrões.

Abstract. This project presents an Artificial Intelligence application for image segmentation of visual assemblies made by children. The work is grounded in computer vision and deep learning, using images of figures composed of cut-out pieces to train a model capable of individually identifying and delimiting each assembly component. A dataset of digital images provided by the Center for Biological and Health Sciences of Universidade Presbiteriana Mackenzie was used, with manual segmentation annotations on the Roboflow platform. The adopted model was YOLOv11 (Ultralytics), selected for its instance segmentation capabilities. Results showed solid performance, with mAP@0.5 of 0.995 and F1-Score of 0.99, demonstrating that the model accurately recognized and delimited regions of interest. The project demonstrates the practical application of AI techniques in a real visual analysis problem, without replacing human evaluation, but acting as a complementary support tool.

Keywords: artificial intelligence; computer vision; image segmentation; deep learning; YOLOv11; pattern analysis.

1. Introdução

A Inteligência Artificial tem sido cada vez mais utilizada em problemas que envolvem reconhecimento de padrões, classificação, detecção de objetos e análise de imagens. Dentro desse campo, a visão computacional se destaca por permitir que sistemas computacionais interpretem imagens digitais, identifiquem objetos, delimitem regiões de interesse e extraiam informações estruturais relevantes.

No contexto deste projeto, a aplicação de IA está voltada à análise de imagens de montagens visuais infantis. Essas imagens representam figuras compostas por peças recortadas, organizadas de diferentes formas. A análise manual desse tipo de material pode envolver variações de interpretação, especialmente quando se deseja observar a presença, o contorno e a disposição das peças. Por isso, técnicas de segmentação de imagens podem contribuir para uma análise mais objetiva e padronizada.

A justificativa do projeto está na necessidade de aplicar técnicas de Inteligência Artificial em um problema real de análise visual. A utilização de um modelo de aprendizado profundo permite transformar uma imagem bruta em informações estruturadas, como a identificação das peças, seus contornos e suas respectivas classes.

O objetivo geral deste projeto é desenvolver e avaliar um modelo de Inteligência Artificial capaz de segmentar peças presentes em imagens de montagens visuais infantis. Como objetivos específicos, o projeto busca: organizar um dataset; realizar a anotação manual das peças; treinar um modelo YOLOv11; avaliar o desempenho por métricas quantitativas; e demonstrar a aplicação prática de IA em um problema real de análise visual.

A proposta se enquadra na Opção Framework, utilizando técnicas de Machine Learning e Deep Learning com o framework YOLOv11/Ultralytics em Python. O artigo está organizado da seguinte forma: Seção 2 descreve o problema; Seção 3 trata dos aspectos éticos; Seção 4 aborda o dataset; Seção 5 detalha a metodologia; Seção 6 apresenta os resultados; Seção 7 conclui o trabalho.

2. Descrição do Problema

O problema abordado neste projeto consiste na identificação automática das peças que compõem uma figura montada a partir de recortes. Cada imagem apresenta uma configuração visual específica, na qual as peças podem aparecer em diferentes posições e orientações. A análise manual dessas imagens pode ser trabalhosa e sujeita a variações, principalmente quando é necessário verificar cada componente individualmente.

Dessa forma, o projeto propõe o uso de Inteligência Artificial para segmentar automaticamente as peças presentes nas imagens. A segmentação permite que o sistema delimite cada região de interesse, identifique a classe correspondente e gere informações visuais úteis para análise posterior.

3. Aspectos Éticos do Uso da IA e Responsabilidade no Desenvolvimento da Solução

O uso de Inteligência Artificial em contextos que envolvem imagens relacionadas a crianças exige cuidado ético e responsabilidade. Neste projeto, a IA é utilizada apenas como ferramenta de apoio à análise visual das imagens, sem a finalidade de realizar diagnóstico, classificar crianças ou substituir a interpretação de profissionais especializados.

As imagens utilizadas não devem conter identificação pessoal dos participantes, preservando a privacidade e a segurança dos dados. A base deve ser tratada de forma anonimizada, garantindo que o foco do projeto esteja exclusivamente na análise das peças e das regiões de interesse presentes nas imagens.

A responsabilidade no desenvolvimento da solução envolve limitar claramente o uso da IA preservar os dados utilizados, documentar as etapas do projeto e apresentar os resultados de forma transparente.

4. Dataset, Análise Exploratória e Preparação dos Dados

O dataset utilizado neste projeto foi formado a partir de imagens digitais fornecidas pelo Centro de Ciências Biológicas e da Saúde da Universidade Presbiteriana Mackenzie. A base original contém 99 imagens de figuras montadas, capturadas em contexto experimental controlado e armazenadas em formato digital. As imagens representam montagens realizadas com peças recortadas que, quando corretamente organizadas, formam uma figura reconhecível, no caso, uma maçã.

Cada imagem contém a disposição das peças no momento da montagem, permitindo que o modelo aprenda a identificar visualmente cada componente da figura.

As imagens foram anotadas manualmente com o apoio da plataforma Roboflow. Para cada imagem, foram demarcadas as regiões correspondentes a cada peça da figura por meio de máscaras de segmentação de instâncias. Esse tipo de anotação permite delimitar o contorno de cada objeto presente na imagem, associando-o a uma classe específica.

Foram consideradas classes referentes às peças que compõem a figura. No caso da maçã, o modelo trabalhou com as classes Esquerda, Direita_cima e Direita_baixo. Essa divisão permitiu que o modelo aprendesse a reconhecer cada peça individualmente, mesmo quando as imagens apresentavam pequenas variações de posição, iluminação ou orientação.

Por se tratar de um dataset composto por imagens, não foi realizada uma análise exploratória tradicional de bases tabulares. Assim, não se aplicam diretamente etapas como cálculo de médias, desvios, valores nulos em colunas, outliers numéricos ou padronização de variáveis textuais.

No entanto, isso não significa ausência de análise dos dados. A análise exploratória foi conduzida de forma compatível com a natureza visual do dataset. Em vez de trabalhar com estatísticas tabulares, a exploração concentrou-se na verificação da organização estrutural da base, dos formatos dos arquivos, da integridade das imagens e da separação entre os conjuntos de treino, validação e teste.

A preparação dos dados envolveu a organização das imagens em subconjuntos de treino, validação e teste. Essa divisão é importante para permitir que o modelo seja treinado com uma parte dos dados e avaliado em imagens não utilizadas diretamente no treinamento.

Também foram realizadas verificações de integridade dos arquivos e conversão de formatos quando necessário. Arquivos em formato .heic, por exemplo, foram convertidos para .jpeg ou .jpg, facilitando o uso nas ferramentas de anotação e treinamento. Além disso, as imagens foram associadas às suas respectivas marcações de segmentação, permitindo que o modelo aprendesse a relação entre a imagem original e as máscaras esperadas para cada peça.

5. Metodologia

A metodologia do projeto seguiu uma abordagem quantitativa e aplicada, com foco no desenvolvimento de um pipeline de visão computacional para segmentação de imagens. O objetivo foi treinar e avaliar um modelo capaz de identificar automaticamente as peças que compõem a figura analisada.

O desenvolvimento foi dividido nas seguintes etapas: organização do dataset de imagens; anotação manual das peças; divisão da base em treino, validação e teste; treinamento do modelo YOLOv11; avaliação do desempenho por métricas quantitativas; e análise dos resultados obtidos.

O modelo adotado foi o YOLOv11, da Ultralytics. A escolha desse modelo ocorreu por sua eficiência em tarefas de detecção e segmentação de objetos, além do suporte à segmentação de instâncias. Esse recurso é essencial para o projeto, pois permite identificar e delimitar individualmente cada peça da figura.

O YOLOv11 foi treinado com as imagens anotadas manualmente, aprendendo a reconhecer as classes das peças e a gerar máscaras de segmentação para cada uma delas. O treinamento buscou fazer com que o modelo identificasse corretamente não apenas a presença das peças, mas também seus contornos e suas posições na imagem.

O treinamento foi realizado com a base de imagens anotadas. Durante esse processo, o modelo recebeu como entrada as imagens originais e suas respectivas máscaras de segmentação. A partir desses

exemplos, o modelo ajustou seus parâmetros internos para reconhecer padrões visuais associados a cada classe.

O treinamento foi acompanhado por métricas de desempenho utilizadas em tarefas de visão computacional, como mAP, IoU, precisão, revocação e F1-Score. Essas métricas permitem avaliar a qualidade da segmentação produzida pelo modelo, comparando as máscaras previstas com as anotações de referência.

O pipeline desenvolvido pode ser resumido em cinco etapas principais: entrada da imagem, processamento da imagem pelo modelo YOLOv11, identificação das peças presentes na figura, geração das máscaras de segmentação e visualização dos resultados.

Na etapa de inferência, o modelo recebe uma imagem de montagem e retorna as peças detectadas, suas classes e suas respectivas máscaras. Com isso, torna-se possível visualizar quais regiões da imagem foram reconhecidas pelo modelo e avaliar se a segmentação foi realizada corretamente.

6. Resultados Obtidos

O modelo YOLOv11 foi treinado ao longo de 74 épocas sobre as imagens anotadas da base utilizada no projeto. O desempenho foi avaliado por meio de instrumentos como matriz de confusão, curva Precision-Recall e curva F1-Confidence. Esses elementos permitem analisar tanto a capacidade do modelo de identificar corretamente as classes quanto o equilíbrio entre precisão e revocação.

Os resultados indicaram desempenho sólido na tarefa de segmentação das peças da figura. O modelo alcançou mAP@0.5 de 0,995 e F1-Score de 0,99, indicando alta capacidade de identificar e delimitar as regiões de interesse nas imagens avaliadas, conforme a Tabela 1.

Tabela 1 – Resultados de desempenho do modelo YOLOv11.

Métrica	Resultado	Interpretação
mAP@0.5	0,995	Alto desempenho na localização e segmentação das peças.
F1-Score	0,99	Excelente equilíbrio entre precisão e revocação.
Matriz de confusão	Sem confusões relevantes	O modelo diferenciou corretamente as classes das peças.

Fonte: elaborado pelos autores.

O mAP@0.5 = 0,995 demonstra alto desempenho na localização e segmentação das peças. O F1-Score de 0,99 indica equilíbrio entre precisão e revocação. A matriz de confusão reforça o bom desempenho: as classificações corretas aparecem concentradas na diagonal principal, sem confusões significativas entre Esquerda, Direita_cima e Direita_baixo (RUSSELL; NORVIG, 2021).

O modelo conseguiu localizar as regiões correspondentes a cada peça e diferenciar as partes que compõem a figura. Esse resultado atende ao objetivo principal do projeto: aplicar Inteligência Artificial para realizar segmentação de imagens em um problema real com dados próprios.




Figura 1 - Matriz de confusão do modelo de segmentação, demonstrando a classificação correta das peças Esquerda, Direita_cima e Direita_baixo.

A imagem a seguir apresenta um exemplo de inferência do modelo sobre uma montagem da figura da maçã. O sistema identificou automaticamente as três peças principais da figura e gerou as máscaras de segmentação associadas. As marcações visuais mostram a classe prevista e o nível de confiança da detecção.




Figura 2 - Exemplo de imagem segmentada pelo modelo YOLOv11, com identificação das peças Esquerda, Direita_cima e Direita_baixo.

O exemplo demonstra que o modelo conseguiu localizar as regiões correspondentes a cada peça e diferenciar as partes que compõem a figura. Esse resultado atende ao objetivo principal do projeto, que é aplicar Inteligência Artificial para realizar segmentação de imagens em um problema real e com dados próprios.

7. Conclusão

O projeto desenvolvido demonstrou a aplicação prática de técnicas de Inteligência Artificial em um problema real de visão computacional. A partir de um dataset composto por imagens de montagens visuais, foi possível treinar um modelo YOLOv11 capaz de segmentar automaticamente as peças que compõem a figura analisada.

Os resultados obtidos foram satisfatórios, com mAP@0.5 de 0,995 e F1-Score de 0,99, indicando alto desempenho na identificação e delimitação das regiões de interesse. Esses resultados mostram que o modelo conseguiu aprender padrões visuais relevantes a partir das imagens anotadas e aplicar esse aprendizado em novas amostras.

Dessa forma, os objetivos esperados foram alcançados dentro do escopo definido para a disciplina de Inteligência Artificial. A solução conseguiu organizar o dataset, realizar a anotação das imagens, treinar um modelo de segmentação e avaliar seu desempenho por meio de métricas quantitativas.

Como trabalhos futuros, recomenda-se ampliar a base de dados, incluir novas figuras, testar o modelo em cenários mais variados e aprimorar a documentação do pipeline. Também é possível integrar a segmentação a outras etapas de análise visual, sempre mantendo o cuidado ético de não utilizar o sistema como ferramenta diagnóstica autônoma.

Conclui-se, portanto, que o projeto apresenta uma solução coerente com os conteúdos da disciplina, aplicando Deep Learning e visão computacional em uma tarefa de segmentação de imagens, com resultados quantitativos relevantes e potencial de expansão.

8. Referências Bibliográficas

AHMED, Masroor et al. Summarizing Recent Developments on Autism Spectrum Disorder Detection and Classification Through Machine Learning and Deep Learning Techniques. *Applied Sciences*, v. 15, n. 14, p. 8056, jul. 2025.

BENSON, Faith Neema et al. Application of machine learning in early childhood development research: a scoping review. *BMJ Open*, v. 15, n. 8, e100358, ago. 2025.

COPPIN, B. Inteligência artificial. Rio de Janeiro: LTC, 2010.

KHLAIF, Ali Ibrahim; NACEUR, Mohamed Saber; KHERALLAHR, Monji. AI-Driven Classification of Children's Drawings for Pediatric Psychological Evaluation: An Ensemble Deep Learning Approach. *Journal of Robotics and Control*, v. 6, n. 1, p. 124-141, jan. 2025.

MIM, Mithila Akter et al. Exploring Early Learning Challenges in Children Utilizing Statistical and Explainable Machine Learning. *Algorithms*, v. 18, n. 1, p. 20, jan. 2025.

MIYAHARA, Motohide; PIEK, Jan; BARRETT, Nicholas. Accuracy of drawing in a dual-task and resistance-to-distraction study: Motor or attention deficit? *Human Movement Science*, v. 25, n. 1, p. 100-109, fev. 2006.

POLSLEY, Seth et al. Detecting Children's Fine Motor Skill Development using Machine Learning. *International Journal of Artificial Intelligence in Education*, v. 32, n. 4, p. 991-1024, out. 2021.

ROBOFLOW. Roboflow: computer vision platform. 2026. Disponível em: <https://roboflow.com>. Acesso em: 25 maio 2026.

RUSSELL, S.; NORVIG, P. Inteligência artificial. Rio de Janeiro: LTC, 2021.

SZELISKI, R. Computer Vision: Algorithms and Applications. New York: Springer, 2021.

ULTRALYTICS. YOLO Documentation. 2026. Disponível em: <https://docs.ultralytics.com>. Acesso em: 25 maio 2026.