Aplicação de Técnicas de Reconhecimento e Análise de Padrões com Inteligência Artificial no Apoio ao Diagnóstico de Problemas Cognitivos em Crianças

Camila Vitória Rodrigues Leite de Sousa[1], Fernando Morales Peres[2], Guilherme Almeida Roath Machado[3], Gustavo Scalabrini Sampaio[4]

[1]Faculdade de Computação e Informática (FCI)
Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

[2]Programa de graduação em Sistemas de Informação – Faculdade de Computação e Informática (FCI) – Universidade Presbiteriana Mackenzie – São Paulo, SP – Brasil

gustavo.sampaio@mackenzie.br

{10418554, 10417590, 10376788}@mackenzista.com.br

Resumo. *Este projeto situa-se na interseção entre Computação e Desenvolvimento Infantil, investigando como técnicas de Inteligência Artificial e Reconhecimento de Padrões podem apoiar o diagnóstico de problemas cognitivos em crianças. A motivação decorre da necessidade de métodos mais objetivos e ágeis do que avaliações exclusivamente subjetivas, reduzindo incertezas e oferecendo evidências transparentes para profissionais de saúde e educação. O objetivo geral é desenvolver e avaliar uma abordagem que, a partir de desenhos infantis e/ou sinais instrumentais (p. ex., traços digitalizados), extraia características relevantes e produza triagens explicáveis que complementem a decisão clínica. A justificativa repousa no potencial de antecipar intervenções, melhorar a acurácia e promover equidade por meio de explicabilidade e validação. Metodologicamente, o estudo envolve: (i) revisão de literatura; (ii) definição e padronização de dados; (iii) processamento de imagens e engenharia de atributos; (iv) comparação de modelos ML/DL com ênfase em IA; (v) avaliação por métricas (acurácia, sensibilidade, especificidade) e análise de usabilidade. Os resultados alcançados até o momento incluem um mapeamento sistematizado de requisitos, a especificação de um pipeline prototípico e baselines iniciais em conjunto piloto, com indicativos de ganho de precisão frente a heurísticas simples.*

Palavras-chave: *inteligência artificial, diagnóstico infantil, cognição, análise de padrões, aprendizado de máquina, modelo preditivo*

Abstract. *This project lies at the intersection of Computing and Child Development, investigating how Artificial Intelligence and Pattern Recognition techniques can support the diagnosis of cognitive problems in children. The motivation arises from the need for more objective and agile methods compared to exclusively subjective assessments, reducing uncertainties and providing transparent evidence for health and education professionals. The main objective is to develop and evaluate an approach that, based on children's*

drawings and/or instrumental signals (e.g., digitized strokes), extracts relevant features and produces explainable screenings that complement clinical decision-making. The justification rests on the potential to anticipate interventions, improve accuracy, and promote equity through explainability and validation. Methodologically, the study involves: (i) a literature review; (ii) data definition and standardization; (iii) image processing and feature engineering; (iv) comparison of ML/DL models with an AI focus; and (v) evaluation using metrics (accuracy, sensitivity, specificity) and usability analysis. The results obtained so far include systematized requirements mapping, the specification of a prototype pipeline, and initial baselines on a pilot dataset, showing signs of improved precision compared to simple heuristics.

Keywords: *artificial intelligence, child diagnosis, cognition, pattern analysis, machine learning, predictive model*

1. Introdução

A identificação precoce de possíveis dificuldades cognitivas em crianças é um desafio recorrente na prática clínica e educacional, sobretudo porque grande parte dos instrumentos tradicionais ainda depende de avaliações subjetivas, interpretação humana e pouca padronização. Métodos baseados em produções gráficas ou observação comportamental apresentam variações significativas entre avaliadores, o que compromete a consistência diagnóstica (MIYAHARA; PIEK; BARRETT, 2006). Nesse cenário, técnicas de Inteligência Artificial (IA) têm emergido como alternativas promissoras para apoiar decisões, oferecendo meios para captar padrões motores, visuais e comportamentais de maneira mais objetiva e sistemática. Estudos recentes mostram que modelos de aprendizado de máquina apresentam elevado potencial para reconhecer traços cognitivos e identificar sinais compatíveis com distúrbios do desenvolvimento (POLSLEY et al., 2021).

Além da análise gráfica, aplicações de IA vêm se expandindo para diversos domínios do desenvolvimento infantil. Pesquisas demonstram, por exemplo, a capacidade de sistemas computacionais em detectar padrões associados ao transtorno do espectro autista a partir de dados clínicos e comportamentais, ampliando a precisão de triagens iniciais (PAN et al., 2025). A literatura também destaca avanços em modelos inspirados na psicologia do desenvolvimento, que buscam representar relações cognitivas fundamentais, como permanência e causalidade, de maneira mais próxima ao raciocínio humano (PILOTO et al., 2022). Dessa forma, a incorporação de técnicas computacionais no apoio ao diagnóstico infantil tem potencial para reduzir incertezas, acelerar encaminhamentos e fortalecer práticas clínicas baseadas em evidências.

Diante desse contexto, o presente projeto tem como objetivo desenvolver e avaliar uma solução baseada em Inteligência Artificial para apoiar a identificação de possíveis dificuldades cognitivas em crianças, a partir da análise de produções gráficas digitalizadas e da extração de padrões relevantes ao processo de triagem. A proposta se enquadra na opção Framework, por empregar técnicas de Machine Learning e Deep Learning em um problema de classificação aplicado à área da saúde. A justificativa do estudo está no potencial de antecipar intervenções, melhorar a acurácia das análises e promover maior

equidade por meio de modelos explicáveis e validados, oferecendo suporte complementar aos profissionais da saúde e da educação.

2. Referencial Teórico

O estudo do desenvolvimento cognitivo infantil abrange uma convergência de áreas, incluindo psicologia, neurociências, educação e, mais recentemente, Inteligência Artificial. Métodos tradicionais de avaliação, embora amplamente utilizados, enfrentam limitações importantes relacionadas à subjetividade e à variabilidade interavaliadores — fatores que motivam a busca por estratégias mais padronizadas e mensuráveis (MIYAHARA; PIEK; BARRETT, 2006). Nesse contexto, técnicas computacionais têm desempenhado papel crescente, oferecendo análises capazes de identificar padrões sutis em comportamentos motores, traços gráficos e respostas a tarefas específicas (POLSLEY et al., 2021).

Os avanços em machine learning e deep learning têm ampliado a compreensão sobre diferentes manifestações do desenvolvimento infantil. Revisões recentes apontam que modelos supervisionados são amplamente utilizados para investigar indicadores de desenvolvimento em bases multimodais, incluindo imagens, sinais biométricos e registros textuais (BENSON et al., 2025). Abordagens de mineração de dados aplicadas ao desenvolvimento infantil também têm se mostrado úteis para distinguir informações confiáveis de interpretações equivocadas, contribuindo para práticas baseadas em evidências (TAJRIAN et al., 2024).

No campo dos transtornos do desenvolvimento, técnicas computacionais têm alcançado desempenho significativo em múltiplas modalidades de dados. Estudos de magnetoencefalografia (MEG), por exemplo, identificam padrões espaciais capazes de diferenciar crianças com transtorno do espectro autista (BARIK et al., 2023), enquanto análises com sinais cerebrais fNIRS e redes neurais convolucionais demonstram potencial para detectar distúrbios de linguagem (LIANG et al., 2025). Complementarmente, modelos de classificação comportamental baseados em IA têm sido empregados para reduzir vieses humanos e aprimorar o processo de triagem (SHAHAMIRI; THABTAH; ABDELHAMID, 2022).

Outro avanço relevante envolve pesquisas dedicadas a desafios de aprendizagem e desempenho cognitivo em contextos educacionais. Técnicas estatísticas e métodos explicáveis de machine learning têm sido empregados para analisar dificuldades precoces, permitindo interpretações mais claras sobre os fatores que influenciam o desempenho infantil (MIM et al., 2025). Revisões amplas sobre autismo indicam que modelos modernos de IA têm se tornado centrais em estratégias de detecção e classificação desse transtorno, reforçando seu papel na prática clínica (AHMED et al., 2025). No mesmo sentido, abordagens inspiradas no raciocínio infantil têm buscado criar representações mais interpretáveis, aproximando modelos computacionais da cognição humana (PILOTO et al., 2022).

Por fim, estudos recentes apontam que IA explicável desempenha papel crucial para ampliar a confiança de profissionais e responsáveis, especialmente quando aplicada ao desenvolvimento infantil. Pesquisas mostram que combinar desempenho elevado com transparência facilita a adoção de sistemas computacionais de apoio diagnóstico em ambientes clínicos e educacionais (SETEGN; DEJENE, 2025). Assim, o conjunto de evidências demonstra que a integração entre IA, psicologia e análise de padrões

representa um avanço significativo para avaliações mais objetivas, rápidas e fundamentadas.

3. Metodologia

A presente pesquisa segue uma abordagem quantitativa, orientada à análise objetiva de dados e ao desenvolvimento de modelos computacionais capazes de identificar padrões associados ao desempenho cognitivo infantil. Trata-se de um estudo aplicado que busca propor, treinar e avaliar um pipeline de Inteligência Artificial (IA) voltado à triagem de possíveis dificuldades cognitivas. A adoção de métodos quantitativos se alinha ao que tem sido consolidado na literatura de aprendizado de máquina em contextos de desenvolvimento infantil, onde métricas numéricas e análises estatísticas são fundamentais para a validação dos modelos (BENSON et al., 2025).

Os dados utilizados neste projeto consistem em desenhos produzidos por crianças, posteriormente digitalizados e organizados em formato de imagem para compor o dataset da pesquisa. A escolha desse tipo de dado se justifica por sua relação com aspectos como atenção, coordenação motora e funções cognitivas superiores, conforme apontado na literatura (MIYAHARA; PIEK; BARRETT, 2006). Para preparação da base, as imagens passam por etapas de organização, anonimização e padronização, incluindo ajustes de iluminação, contraste e proporção, a fim de reduzir ruídos e tornar o conjunto mais adequado ao processamento computacional (BARIK et al., 2023). Além disso, a análise exploratória em Python buscará verificar a qualidade das imagens, a consistência dos arquivos e a adequação dos dados para treinamento e avaliação dos modelos propostos.

O pipeline computacional foi estruturado em etapas que envolvem pré-processamento, extração de características e classificação. As técnicas de aprendizado profundo foram centrais para essa proposta, com especial foco em Convolutional Neural Networks (CNNs), dada sua comprovada capacidade de aprender representações hierárquicas de imagens produzidas por crianças ou derivadas de tarefas perceptuais (PILOTO et al., 2022). Além disso, adotaram-se modelos ensemble, combinando arquiteturas como VGG16, VGG19 e MobileNet, estratégia que tem se mostrado eficaz na redução de vieses e na melhoria da acurácia em classificações relacionadas ao comportamento infantil (KHLAIF; NACEUR; KHERALLAHR, 2025).

Para complementar o desempenho dos modelos profundos, a metodologia também inclui classificadores tradicionais, como SVM e kNN, utilizados como baselines comparativos. Revisões recentes mostram que esses modelos ainda apresentam resultados robustos em contextos multimodais de desenvolvimento infantil, justificando sua inclusão (BENSON et al., 2025). Como etapa adicional, foram exploradas técnicas de IA explicável, com o intuito de tornar os resultados mais interpretáveis para profissionais da saúde e da educação. A adoção de métodos XAI segue recomendações presentes em estudos que aplicam interpretabilidade à análise de comportamentos e sinais infantis (SETEGN; DEJENE, 2025).

Além disso, foram consideradas diretrizes atuais sobre o uso responsável de IA em contextos sensíveis, especialmente no trabalho com crianças. Estudos recentes destacam que tecnologias generativas e modelos avançados de IA podem desempenhar papel importante na mitigação de impactos associados a transtornos do

neurodesenvolvimento, desde que aplicados com rigor ético e transparência (OLERIBE, 2025). Dessa forma, a metodologia incorpora princípios de segurança, mitigação de vieses e responsabilidade clínica, alinhados às recomendações desse campo emergente.

Por fim, a avaliação dos modelos será realizada por meio de métricas quantitativas como acurácia, sensibilidade, especificidade e matriz de confusão, por serem indicadores relevantes em tarefas de classificação diagnóstica infantil (BARIK et al., 2023). Além da comparação numérica entre os modelos, a análise interpretável será utilizada para identificar quais padrões gráficos contribuíram para cada classificação, tornando os resultados mais compreensíveis para profissionais da saúde e da educação. Como resultados esperados, busca-se obter uma abordagem capaz de produzir triagens mais objetivas, consistentes e explicáveis, com potencial para complementar a avaliação clínica e educacional de crianças com possíveis dificuldades cognitivas.

4. Referências bibliográficas

POLSLEY, Seth et al. Detecting Children's Fine Motor Skill Development using Machine Learning. International Journal of Artificial Intelligence in Education, Springer Science and Business Media LLC, v. 32, n. 4, p. 991–1024, Oct. 2021. ISSN 1560-4306. DOI: 10.1007/s40593-021-00279-7. Available from: https://doi.org/10.1007/s40593-021-00279-7.

OLERIBE, Obinna Ositadimma. Leveraging and Harnessing Generative Artificial Intelligence to Mitigate the Burden of Neurodevelopmental Disorders (NDDs) in Children. Healthcare, MDPI AG, v. 13, n. 15, p. 1898, Aug. 2025. ISSN 2227-9032. DOI: 10.3390/healthcare13151898. Available from: https://doi.org/10.3390/healthcare13151898.

SHAHAMIRI, Seyed Reza; THABTAH, Fadi; ABDELHAMID, Neda. A new classification system for autism based on machine learning of artificial intelligence. Technology and Health Care, SAGE Publications, v. 30, n. 3, p. 605–622, May 2022. ISSN 1878-7401. DOI: 10.3233/THC-213032. Available from: https://doi.org/10.3233/THC-213032.

MIYAHARA, Motohide; PIEK, Jan; BARRETT, Nicholas. Accuracy of drawing in a dual-task and resistance-to-distraction study: Motor or attention deficit? Human Movement Science, Elsevier BV, v. 25, n. 1, p. 100–109, Feb. 2006. ISSN 0167-9457. DOI: 10.1016/j.humov.2005.11.004. Available from: https://doi.org/10.1016/j.humov.2005.11.004.

KHLAIF, Ali Ibrahim; NACEUR, Mohamed Saber; KHERALLAHR, Monji. AI-Driven Classification of Children's Drawings for Pediatric Psychological Evaluation: An Ensemble Deep Learning Approach. Journal of Robotics and Control (JRC), Universitas Muhammadiyah Yogyakarta, v. 6, n. 1, p. 124–141, Jan. 2025. ISSN 2715-5056. DOI: 10.18196/jrc.v6i1.23302. Available from: https://doi.org/10.18196/jrc.v6i1.23302.

PILOTO, Luis S. et al. Publisher Correction: Intuitive physics learning in a deep-learning model inspired by developmental psychology. Nature Human Behaviour, Springer Science and Business Media LLC, v. 6, n. 8, p. 1181–1181, July 2022. ISSN 2397-3374. DOI: 10.1038/s41562-022-01432-5. Available from: https://doi.org/10.1038/s41562-022-01432-5.

ABDUL-HAFEZ, Hamza A. et al. Pediatric Emergency Department Diagnostics: Global Challenges and Innovations. Current Treatment Options in Pediatrics, Springer Science and Business Media LLC, v. 11, n. 1, July 2025. ISSN 2198-6088. DOI: 10.1007/s40746-025-00333-9. Available from: https://doi.org/10.1007/s40746-025-00333-9.

AHMED, Masroor et al. Summarizing Recent Developments on Autism Spectrum Disorder Detection and Classification Through Machine Learning and Deep Learning Techniques. Applied Sciences, MDPI AG, v. 15, n. 14, p. 8056, July 2025. ISSN 2076-3417. DOI: 10.3390/app15148056. Available from: https://doi.org/10.3390/app15148056.

LIANG, Aimin et al. Classification of Children With Developmental Language Disorder Using Task fNIRS Data and Convolutional Neural Network. IEEE Journal of Selected Topics in Quantum Electronics, Institute of Electrical and Electronics Engineers (IEEE), v. 31, p. 1–9, July 2025. ISSN 1558-4542. DOI: 10.1109/JSTQE.2024.3519572. Available from: http://doi.org/10.1109/JSTQE.2024.3519572.

BARIK, Kasturi et al. Autism Detection in Children using Common Spatial Patterns of MEG Signals. IEEE, p. 1–4, July 2023. DOI: 10.1109/EMBC40787.2023.10340449. Available from: https://doi.org/10.1109/EMBC40787.2023.10340449.

MIM, Mithila Akter et al. Exploring Early Learning Challenges in Children Utilizing Statistical and Explainable Machine Learning. Algorithms, MDPI AG, v. 18, n. 1, p. 20, Jan. 2025. ISSN 1999-4893. DOI: 10.3390/a18010020. Available from: https://doi.org/10.3390/a18010020.

TAJRIAN, Mehedi et al. Analysis of child development facts and myths using text mining techniques and classification models. Heliyon, Elsevier BV, v. 10, n. 17, e36652, Sept. 2024. ISSN 2405-8440. DOI: 10.1016/j.heliyon.2024.e36652. Available from: https://doi.org/10.1016/j.heliyon.2024.e36652.

PAN, Ning et al. Developing a simplified measure to predict the risk of autism spectrum disorders: Abbreviating the M-CHAT-R using a machine learning approach in China. Psychiatry Research, Elsevier BV, v. 344, p. 116353, Feb. 2025. ISSN 0165-1781. DOI: 10.1016/j.psychres.2025.116353. Available from: https://doi.org/10.1016/j.psychres.2025.116353.

SETEGN, Gizachew Mulu; DEJENE, Belayneh Endalamaw. Improving machine learning models through explainable AI for predicting the level of dietary diversity among Ethiopian preschool children. Italian Journal of Pediatrics, Springer Science and Business Media LLC, v. 51, n. 1, Mar. 2025. ISSN 1824-7288. DOI: 10.1186/s13052-025-01892-1. Available from: https://doi.org/10.1186/s13052-025-01892-1.

BENSON, Faith Neema et al. Application of machine learning in early childhood development research: a scoping review. BMJ Open, BMJ, v. 15, n. 8, e100358, Aug. 2025. ISSN 2044-6055. DOI: 10.1136/bmjopen-2025-100358. Available from: http://doi.org/10.1136/bmjopen-2025-100358.